



学 院	
编 号	

西安交通大学

硕士研究生学位论文选题报告

学 号： 3124354083

研 究 生： 施佳希

导 师： 胡建晨

论文题目： 面向多楼层场景的多机器人协同配送与计算资源调度研究

学 科： 控制工程

填写时间： 2026 年 1 月 1 日

硕士研究生学位论文选题报告管理规定

硕士学位论文选题报告是做好学位论文的基础，为了完善硕士研究生过程质量监控体系，提高硕士研究生培养质量，要求在校硕士生必须在入学第三学期内，完成学位论文选题报告。

一、硕士生在查阅一定的国内外文献资料基础上，填写完成《硕士研究生学位论文选题报告》。

二、《硕士研究生学位论文选题报告》完成以后，应组织公开的学位论文选题报告会。

三、选题报告会由系、所以上单位负责组织，至少由 3 名副高以上人员组成，其中 1 名担任组长。并在选题报告会后负责就选题的意义、文献综述、研究内容、可能遇到的问题、是否同意选题等写出结论性的审查意见，并将结果和相关材料留学院备案。

四、《硕士研究生学位论文选题报告》由各学院归档。

五、《硕士研究生学位论文选题报告》必须采用 A4 纸双面打印，左侧装订成册，各栏空格不够时，请自行加页。格式可在研究生院主页下载。

论文题目：

论文类型：（1）基础研究；（2）应用基础研究；（3）应用研究；（4）其它

课题来源：（1）纵向课题；（2）横向课题；（3）自选课题；（4）其它

一、选题的科学依据（1、选题背景；2、理论意义和应用价值；3、国内外研究现状及发展趋势。附主要参考文献及出处）

1. 选题背景

随着智能物流与楼宇自动化技术的快速迭代，末端配送作为连接物流链路与终端用户的关键环节，其服务质量与运营效率直接关乎行业发展上限与用户核心体验。当前，城市中高层公寓楼、商务写字楼、综合园区等多楼层建筑已成为主流载体，对应的末端快递与物资配送需求持续攀升。传统“人工上门配送”模式受限于人力成本激增、高峰时段运力缺口大等问题，已难以匹配规模化、精细化的配送需求（图 1 所示）。在此背景下，多机器人协同完成多楼层快递/物资配送的应用场景应运而生，该场景能够通过机器人的自主协同作业，大幅提升配送效率、降低人力依赖，同时精准适配多楼层楼宇的复杂环境布局，成为推动末端配送智能化转型的核心方向。




图 1 传统人工配送

多机器人多楼层配送场景具有显著的复杂协同特性，核心体现在多目标优化与多主体协调的双重需求上。从场景构成来看，该场景涉及多机器人、多电梯、多任务三大核心要素：多机器人需在不同楼层间灵活穿梭，执行正向配送（从底层取件至目标楼层）与逆向寄件（从目标楼层取件至底层）等多样化任务；多电梯作为跨楼层移动的唯一核心载体，其运行效率直接决定机器人的跨层作业节奏；而海量任务存在优先级差异、用户取件时间窗口约束等特性，进一步提升了场景的协同复杂度。从优化目标来看，该场景需实现多维度目标的平衡优化，包括提升任务完成效率、提高电梯与机器人的资源利用率、降低整体运营能耗、保障任务配送准时性等，多目标之间存在

相互约束与耦合关系，构成了场景的核心技术需求。

在该应用场景的落地过程中，现有技术方案存在诸多适配短板，进一步凸显了针对性技术研发的必要性。一方面，在机器人环境感知与定位环节，当前主流的激光雷达、双目视觉等传感器方案成本高昂，显著提升了多机器人部署的规模化成本，难以满足行业大规模应用的性价比需求，而单目视觉方案因成本低廉、部署便捷，成为更具推广潜力的替代方案，但需攻克单目深度估计的精度保障问题以适配电梯按钮定位等精细操作需求。另一方面，在机器人与电梯的协同交互环节，现有方案多依赖电梯物联网接口改造与机器人联网联动，但不同品牌、不同年代的电梯设备接口不统一，改造难度大、周期长、成本高，且联网改造过程中存在数据隐私泄露风险，难以实现通用性适配，因此亟需探索无需大规模联网改造的自主交互方案，如基于机械臂的电梯按钮自主按压技术，以降低场景落地门槛。

值得注意的是，上述场景中的多目标优化、环境感知精度保障、多主体协同决策等核心任务，均依赖大量复杂的推理计算支撑，而机器人搭载的嵌入式系统普遍存在计算资源受限的瓶颈。受限于体积、功耗及成本约束，嵌入式终端难以配备高性能计算单元，无法独立承载大规模并行推理任务（如多目标检测、路径规划算法迭代、多机器人协同策略求解等），若强行在本地执行复杂推理，极易导致任务处理延迟增加、决策响应滞后，进而影响配送效率与服务可靠性。与之相对的是，当前城市楼宇及物流园区普遍已实现高速网络覆盖，富裕的网络带宽为计算资源的远程调度提供了可行条件，使得将复杂推理任务迁移至云端进行集中式处理成为破解嵌入式计算瓶颈的有效路径。但云端推理面临着 GPU 资源的高效调度难题：多机器人产生的推理任务具有显著的动态性与异构性，不同任务（如实时定位推理、路径优化求解、电梯交互决策等）对 GPU 算力的需求、任务执行的优先级及时间窗口约束存在差异，如何合理规划“何时将何种任务分配至哪块 GPU”，实现 GPU 资源的负载均衡，保障高优先级任务的实时响应，同时降低跨端云传输延迟与整体计算能耗，成为衔接云-端协同架构、保障多机器人多楼层配送场景高效运行的关键技术支点。

综上，多机器人多楼层快递/物资配送场景具有明确的应用价值与现实需求，其蕴含的多目标优化、多机器人-多电梯-多任务协调等核心特性，以及现有传感器成本过高、电梯联网改造难度大、嵌入式计算资源受限等现实痛点，共同构成了本研究的核心背景。开展针对该场景的专项研究，探索适配场景需求的技术方案，尤其是云-端协同下的推理任务 GPU 资源调度策略，能够有效破解当前多楼层末端配送的智能化转型难题，推动多机器人技术在楼宇自动化领域的规模化应用，具有重要的现实应用价值与

行业推广意义。

2. 理论意义和应用价值

本研究在理论和方法的层面具有以下重要意义：

（1）完善多智能体协同调度理论体系，针对多机器人、多电梯与多任务动态耦合的复杂场景，构建适配资源受限与动态不确定环境的多目标优化调度模型，突破传统单一场景调度理论框架，为同类协同调度问题提供新的理论思路与求解范式；

（2）深化单目视觉感知理论在精细操作场景的应用，针对电梯按钮定位等小目标、弱纹理场景，优化单目深度估计的特征提取与模型构建方法，丰富复杂环境下单目视觉深度恢复的理论支撑；

（3）建立机器人自主交互、跨楼层移动与资源调度的融合理论体系，在探索机械臂操作与视觉感知协同机制、形成“环境感知-动作决策-执行反馈”闭环理论模型的基础上，构建面向单目深度估计推理任务的 GPU 资源调度机制，明确不同机器人在不同任务阶段的 GPU 调用策略，实现资源受限场景下资源利用率的最大化与资源碎片的最小化，填补多机器人作业与后端资源协同调度的理论空白，为异构资源与多智能体作业的协同优化提供通用理论参考。

本研究的成果具有明确的实践应用前景与社会经济价值：

（1）破解多楼层末端配送行业痛点，通过多机器人协同调度方案与低成本单目视觉-机械臂按电梯技术，结合单目深度估计推理任务的 GPU 动态调度机制，进一步降低推理阶段的资源占用成本与硬件部署成本，显著提升配送效率与准时率，为智能物流企业提供高性价比末端配送解决方案，适配电商大促等高峰任务需求；

（2）降低楼宇自动化改造与运营成本，无联网自主按电梯技术可直接适配不同品牌、年代的电梯设备，规避传统联网改造的高难度与高成本问题，同时通过 GPU 资源调度优化提升资源利用率、降低能耗与监管成本，推动多机器人技术在多楼层场景规模化落地；

（3）拓展多机器人技术应用边界，形成的协同调度、视觉感知、机械臂操作与资源调度融合技术可迁移至楼宇巡检、设备维保、应急物资转运等领域，赋能楼宇自动化升级，助力智慧城市楼宇服务数字化转型；

（4）提供灵活可扩展的个性化解决方案，通过参数调整与模型优化适配不同规模、类型的多楼层场景，满足小型公寓日常配送与大型园区多物资转运等多样化需求，提升技术落地的普适性。

3.国内外研究现状及发展趋势

3.1 多任务规划

在多机器人多楼层协同作业场景中，跨楼层路径规划与电梯资源调度是制约系统效能的核心瓶颈，国内外学者围绕该瓶颈开展了一系列针对性研究。Han 等^[1]构建了融合电梯等待时间的路径规划模型，将电梯明确纳入关键约束节点范畴，系统界定了多楼层机器人“移动-换乘-执行”的全流程衔接逻辑，为跨楼层路径与电梯资源的协同优化提供了基础框架；François 等^[2]聚焦多电梯、多任务点的巡逻路径优化需求，提出带时间窗的自适应大邻域搜索（ALNS）算法用于求解多趟车辆路径问题（MTVRP），为复杂场景下的路径规划求解提供了关键算法支撑，但该算法方案在应对大规模作业场景时，系统扩展性不足的问题较为突出；为此，Kobayashi 等^[3]针对性提出 LR-PT 分布式算法，通过赋予机器人自主区域划分能力与基站态势感知功能，有效弥补了大规模场景下系统扩展性的短板，显著增强了多楼层多电梯环境下巡逻系统的鲁棒性与协同效率；Ward 等^[4]则从感知与通信维度切入，通过优化机器人与电梯的交互机制，实现了对电梯状态变化的实时响应，提升了系统的动态适配能力。总体而言，现有研究从模型构建、算法设计等多维度形成了阶段性成果，但仍存在明显不足：**现有方案中的机器人多依靠与电梯联网实现协同控制，该模式不仅成本较高，且对既有电梯系统的改造难度较大，限制了技术的实际落地应用。**

3.2 单目深度估计

单目深度估计具有成本低等优点，适用于机器人相关应用场景。单目深度估计的技术方法主要分为判别式与生成式两类，早期的单目深度估计以判别式方法为主，该方法核心通过学习图像到深度图的映射关系实现端侧高效推理，但传统模型存在泛化性差、实时性不足等问题。从率先实现跨数据集泛化的 MiDaS^[5]，到借助大规模无标注数据预训练的 Depth Anything 系列^[6]，该类方法通过扩大数据与模型规模持续提升性能，其中 Depth Anything2 系列有效弥补了传统判别式模型的泛化性短板；微软 MoGE 系列^[7]进一步突破多任务割裂的局限，而 MoGE-2 更攻克了传统单目方法的尺度歧义性痛点，实现单模型度量尺度估计，大幅提升工程实用价值。

尽管判别式方法在效率上优势显著，但在弱纹理、小目标等复杂场景下仍存在鲁棒性瓶颈，生成式方法由此成为新兴突破方向。该方法依托生成模型的强大视觉先验弥补复杂场景适配不足的问题，其中主流思路是将扩散模型适配于深度估计任务。

Marigold^[8,9]等先驱工作率先验证了微调 T2I 模型完成深度估计的可行性，有效解决了

判别式方法在复杂场景的性能短板；后续 GenPercept^[10]等研究则针对生成式模型推理延迟高的核心缺陷，通过优化采样流程与训练目标实现单步推理，推动生成式方法向端侧部署落地迈进。然而，现有生成式单目深度估计方法在视频序列推理场景中仍存在明显短板，不仅面临前后帧深度预测结果不一致的问题，还存在视频推理速度慢、难以满足实时性需求的技术瓶颈。

3.3 GPU 资源调度

在单目深度估计推理任务中，嵌入式硬件普遍存在计算资源受限的问题，难以支撑复杂的深度估计与多任务协同运算，因此转向云端计算成为主流解决方案。而云计算场景下，如何通过高效的 GPU 调度控制成本，成为核心优化方向。针对云端训练推理等多任务并发需求，Han 等^[11]设计了时空共享的多 GPU 推理调度器，该方案能够在保障核心深度估计任务推理性能的前提下，高效协调多任务资源分配，初步实现了 GPU 资源的集约化利用；但该多 GPU 配置方案在中小规模部署场景中仍存在成本偏高的问题，且未充分适配不同算力需求的灵活调度场景。鉴于此，Zhao 等^[12]提出的单 GPU 内多任务调度策略形成有效补充，其通过精细化分配单 GPU 内部资源、最大化提升资源利用率来强化并发处理能力，既能匹配轻量化部署需求，又能进一步压缩硬件投入成本，为嵌入式受限场景下依托云计算实现低成本、高效能的单目深度估计推理提供了更适配的调度方案。以上这些研究均针对实时场景进行调度，仅围绕当前已到达的任务展开资源协调，缺乏对未来任务需求的预判与提前规划；与之不同的是，在多机器人协同配送场景中，结合电梯运行静止期、机器人运动轨迹等信息，能够精准预知未来短时间内的任务需求，这为构建更具前瞻性的调度模型创造了条件。

参考文献

- [1]HAN L H, et al. The path planning problem of robotic delivery in multi-floor hotel environments[J]. Sensors, 2025, 25(6): 1783.
- [2]FRANÇOIS V, ARDA Y, CRAMA Y. Adaptive large neighborhood search for multitrip vehicle routing with time windows[J]. Transportation Science, 2019, 53(6): 1706-1730.
- [3]KOBAYASHI K, et al. Distributed algorithm with emergent area partitioning and base station's situation awareness for multi-robot patrolling[J]. Journal of Robotics and Mechatronics, 2025, 37(4): 927-944.
- [4]WARD J C, RICHARDS A, HUNT E R. Practical handling of dynamic environments in decentralised multi-robot patrol[C]//Towards Autonomous Robotic Systems. Proceedings of the Annual Conference.

Cham: Springer Nature Switzerland, 2025: 45-56.

[5]RANFTL R, LASINGER K, HAFNER D, et al. Towards robust monocular depth estimation: Mixing datasets for zero-shot crossdataset transfer[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, 44(3): 1623-1637.

[6]YANG L H, KANG B Y, HUANG Z L, XU X G, FENG J, ZHAO H. Depth Anything: Unleashing the Power of Large-Scale Unlabeled Data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2024: 10371-10381.

[7]WANG R C, OBUKHOV A, HUANG S Y, METZGER N, CAYE DAUDT R, SCHINDLER K. MoGE: Unlocking accurate monocular geometry estimation for open-domain images with optimal training supervision[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2025: 9492-9502.

[8]KE B X, OBUKHOV A, HUANG S Y, METZGER N, CAYE DAUDT R, SCHINDLER K. Repurposing diffusion-based image generators for monocular depth estimation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New York: IEEE, 2024: 9492-9502.

[9]KE B X, QU K, WANG T F, METZGER N, HUANG S Y, LI B, OBUKHOV A, SCHINDLER K. Marigold: Affordable adaptation of diffusion-based image generators for image analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, preprint(accept): 1-18.

[10]KE B X, QU K, WANG T F, METZGER N, HUANG S Y, LI B, OBUKHOV A, SCHINDLER K. Marigold: Affordable adaptation of diffusion-based image generators for image analysis[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025, preprint(accept): 1-18.

[11]HAN Z, ZHOU R, XU C, et al. InSS: An intelligent scheduling orchestrator for multi-GPU inference with spatio-temporal sharing[J]. IEEE Transactions on Parallel and Distributed Systems, 2024, 35(10): 1735-1748.

[12]ZHAO X, WANG H, HUANG A, et al. Cluster-aware scheduling in multitasking GPUs[J]. Real-Time Systems, 2024, 60: 1-23.

二、主要研究内容和方案

主要研究内容

1. 跨楼层批量配送任务的多移动机器人高效路径规划研究

针对多机器人多楼层配送中电梯资源竞争、跨楼层路径衔接不畅及配送时效与能耗冲突的核心问题，基于多目标整数规划理论，考虑任务优先级、用户取件时间窗口、机器人载重与续航约束及电梯动态运行状态，研究双目标优化模型构建与高效求解问题；面向多机器人-多电梯-多任务动态耦合场景，利用分层协同优化架构（任务分配层、路径规划层、电梯调度层），结合电梯到达时间预测与动态重求解机制，研究融合电梯约束的任务最优分配与跨楼层路径规划方法，最终实现配送总时间最短与系统总能耗最小的协同优化目标，保障多楼层配送的高效性与稳定性。

2. 基于单目视觉的移动机器人自主按压电梯按钮深度定位

针对单目深度估计在电梯按钮定位等弱纹理、小目标场景下鲁棒性不足、尺度歧义的问题，基于预训练 VAE（变分自动编码器）与 DiT（Diffusion Transformer）架构，考虑 RGB 图结构信息、任务引导文本意图与随机噪声可控性，研究多模态输入融合与深度生成模型优化问题；面向机器人精细操作的精度需求，利用流匹配损失约束潜空间生成轨迹、一致性损失修正像素级几何误差，研究模型训练策略与架构轻量化设计，提升深度估计的泛化能力、度量精度与实时性，为机器人自主按压电梯按钮等精细操作提供可靠的深度感知支撑。

3. 移动机器人端嵌入式计算资源受限下的计算任务资源调度方法

针对多机器人嵌入式计算资源受限、云端 GPU 显存碎片导致资源利用率低与任务等待时间延长的问题，基于混合整数线性规划（MILP），考虑机器人运动时序（电梯运行静止期）、推理任务显存需求分布与 GPU 集群资源状态，研究显存碎片率量化与最优迁移调度问题；面向云-端协同推理场景，利用碎片感知机制与静止期迁移窗口，结合剩余显存适配度分配策略，研究推理任务动态迁移与 GPU 资源优化配置方法，实现集群总显存碎片率最小化，提升 GPU 资源利用率与机器人推理任务的无缝协同效率，降低云端计算成本。

研究方案

本研究设计一种多机器人多楼层送货系统，包括机器人路径规划、计算机视觉、计算资源调度三大方面，如图 2 所示。




图 2 研究架构

1.多送货机器人多任务协同调度

1.1 核心研究内容

针对多机器人在多楼层环境执行外卖/快递配送任务，面临电梯资源竞争、跨楼层路径衔接、配送时效与能耗冲突等问题，构建送货时间最短、系统总能耗最小的多目标优化模型，设计融合电梯动态约束的任务分配与路径规划方案，实现多机器人-多电梯协同高效低耗配送。

1.2 总体研究方案

采用分层协同优化架构，分为任务分配层、路径规划层、电梯调度层，基于多目标整数规划方法求解双目标最优解，结合电梯运行状态预测实现动态调度，最终输出最优任务分配结果与配送路径，指导机器人执行配送任务。

1.3 关键模型与公式

1.3.1 双目标优化目标函数

目标 1：送货总时间最短。表征所有配送任务的整体完成效率，为最后完成任务的结束时间。

$$F_1 = T_{\text{total}} = \max_{1 \leq i \leq N} (t_i^{\text{end}}) \quad (1-1)$$

式(1-1)中， N 为配送任务总数， t_i^{end} 为第 i 个配送任务的实际完成时间。

目标 2：系统总能耗最小。系统总能耗为机器人行驶能耗与电梯调度能耗之和，如(1-2)所示：

$$F_2 = E_{\text{total}} = E_{\text{robot}} + E_{\text{elevator}} \quad (1-2)$$

其中，机器人行驶总能耗如(1-3)所示：

$$E_{\text{robot}} = \sum_{j=1}^M \sum_{i=1}^N x_{ij} \cdot D_i \cdot \mu_j \quad (1-3)$$

电梯调度总能耗如(1-4)所示：

$$E_{\text{elevator}} = \sum_{e=1}^E |L_e^{\text{tar}} - L_e^{\text{cur}}| \cdot \lambda_e \cdot \sum_{j=1}^M x_{ij} \cdot I_{ije} \quad (1-4)$$

其中， M 为机器人数量， $x_{ij} \in \{0, 1\}$ 为决策变量（ $x_{ij} = 1$ 表示机器人 j 执行任务 i ）； D_i 为任务 i 的配送距离， μ_j 为机器人 j 单位距离能耗系数； E 为电梯数量， L_e^{tar} 、 L_e^{cur} 为电梯 e 的目标/当前楼层， λ_e 为电梯 e 单位楼层能耗系数， I_{ije} 为 0-1 变量（ $I_{ije} = 1$ 表示机器人 j 执行任务 i 需使用电梯 e ）。

1.3.2 约束条件

约束 1：任务唯一性约束。每个配送任务仅能分配给 1 台机器人执行，无任务遗漏、无重复分配，如(1-5)所示。

$$\sum_{j=1}^M x_{ij} = 1, \quad \forall i \in \{1, 2, \dots, N\} \quad (1-5)$$

其中， $x_{ij} \in \{0, 1\}$ ， $x_{ij} = 1$ 表示机器人 j 分配执行配送任务 i ； M 表示机器人总数。

约束 2：机器人载重约束。单台机器人分配的所有任务货物总重量，不超过该机器人的最大载重能力，引入机器人视觉，识别当前电梯轿厢内人数。如(1-6)所示。

$$\sum_{i=1}^N x_{ij} \cdot W_i \leq W_j^{\max}, \quad \forall j \in \{1, 2, \dots, M\} \quad (1-6)$$

其中， N 表示任务总数， W_i 为任务 i 的货物重量， $W_j^{\max}$ 为机器人 j 的最大载重阈值。

约束 3：机器人续航约束。单台机器人分配的所有任务配送总距离，不超过该机器人的最大续航里程，如(1-7)所示。

$$\sum_{i=1}^N x_{ij} \cdot D_i \leq D_j^{\max}, \quad \forall j \in \{1, 2, \dots, M\} \quad (1-7)$$

其中， D_i 为任务 i 的配送距离， $D_j^{\max}$ 为机器人 j 的最大续航阈值。

约束 4：电梯承载量约束。单部电梯同一时段内，承载的执行配送任务的机器人数量，不超过电梯最大承载数量，如(1-8)所示。

$$\sum_{j=1}^M \sum_{i=1}^N x_{ij} \cdot I_{ije} \leq Q_e, \quad \forall e \in \{1, 2, \dots, E\} \quad (1-8)$$

其中， Q_e 为电梯 e 的最大机器人承载数量， $I_{ije} = 1$ 表示机器人 j 执行任务 i 需使用电梯 e 。

1.4 协同优化执行流程

协同优化流程如图 1 所示。该流程围绕机器人跨楼层配送业务，先完成任务、机器人、电梯基础数据初始化，通过多目标优化算法实现任务与机器人的最优分配，结合电梯到达时间预测规划机器人最优配送路径，同时实时更新状态并对异常/新增任务动态重求解，最终筛选综合最优方案指导机器人完成配送，实现高效、精准的跨楼层配送调度。




图 3 协同优化流程图

2.单目深度估计

2.1 主要研究内容

2.1.1 模型架构设计

（1）多模态输入编码模块

如图 2 所示，将目标深度图、参考 RGB 图分别输入冻结的 VAE（变分自动编码器）（图中“冻结”标识），编码为固定维度的图像潜空间特征（图中蓝色模块），复用预训练 VAE 的图像表征能力；将任务引导文本（如“生成深度图并保持原始场景结构”）输入冻结的文本编码器（TE），编码为文字潜空间特征（图中绿色模块），实现任务意图的精准引导；添加随机噪声空间特征（图中黄色模块），为生成过程提供可控随机性，提升深度图的多样性与鲁棒性。

（2）核心生成模块

以可学习的 DiT（DiffusionTransformer）Block 为骨干（图中“可学习”标识），每个 DiTBlock 包含 FeedForward 与 Self-Attention 子模块，接收“文字+图像+噪声”的多模态潜特征，通过 Self-Attention 机制融合 RGB 图的结构信息与文本的任务引导，实现从参考 RGB 图到深度图的生成式变换，同时保持场景结构一致性。

（3）输出解码模块

生成的潜特征经冻结的 VAE 解码器（图中右侧 VAE）还原为像素空间的预测深度图，完成从潜空间到实际深度图的映射。

2.1.2 训练策略优化

（1）流匹配损失

针对潜空间的生成轨迹进行约束：在目标深度图潜特征中注入高斯噪声，让模型学习“从含噪声潜特征还原纯净深度潜特征”的映射逻辑，保障生成过程的连续性与潜空间表征精度。

（2）一致性损失

针对像素空间的几何结构进行约束：直接计算预测深度图与真实深度图的像素级差异，修正深度图的几何细节误差，确保深度图与原始 RGB 图的场景结构一致。




图 4 单目深度估计模型架构图

3.推理任务调度

3.1 核心研究内容

针对多机器人在多楼层环境执行推理任务时，GPU 显存碎片导致资源利用率低、

任务等待时间延长的问题，以机器人静止期（电梯运行阶段）为迁移触发时机，构建 GPU 显存碎片率最小化的单目标优化模型，设计基于实时显存状态的推理任务迁移调度方案，实现 GPU 资源高效利用与机器人推理任务无缝协同。

3.2 总体研究方案

采用“碎片感知+静止期迁移”的协同优化架构，分为显存状态监测层、迁移决策层、任务调度层。基于历史推理任务的显存需求分布，定义动态碎片率指标；在机器人乘坐电梯的静止时段，通过混合整数线性规划（MILP）求解最优迁移方案，整合零散显存资源；新任务到达时采用适配显存特性的放置策略，最终实现碎片率降低与推理效率提升的双重目标。

3.3 关键模型与公式

3.3.1 系统基础定义

硬件配置：集群含若干服务器，单服务器配置 8 张同规格 GPU，单 GPU 显存容量为 $V_{\max}$ （固定值），显存为不可分割的最小分配单位。

推理任务属性：任务 j 表征为元组 $j = (v_j, t_j, a_j)$ ，其中 v_j 为任务所需显存大小（已知）， t_j 为推理执行时间（已知）， a_j 为任务到达时间。

迁移触发时机：机器人执行跨楼层推理任务时，乘坐电梯的静止时段为唯一迁移窗口，此时任务迁移不影响推理连续性，迁移耗时相对于电梯运行时间可忽略。

3.3.2 显存碎片率定义

碎片率随 GPU 显存剩余量动态变化，核心考虑剩余显存对未来推理任务的适配能力——剩余显存无法容纳任何典型推理任务时，碎片率最高；剩余显存可匹配多数任务需求时，碎片率最低。

（1）任务显存需求分布

基于历史推理任务数据，统计显存需求离散集合 $S = \{s_1, s_2, \dots, s_k\}$ ，定义需求分布概率 π_s ：

$$\pi_s = \frac{\text{历史中显存需求为 } s \text{ 的任务数量}}{\text{历史任务总数量}} \quad (3-1)$$

其中 $\sum_{s \in S} \pi_s = 1$ ，通过拉普拉斯平滑降低噪声影响。

（2）单 GPU 碎片率函数

设单 GPU 当前剩余显存为 r_p ($0 \leq r_p \leq V_{\max}$)，定义碎片率函数 $\phi(r_p)$ 为剩余显存无法容纳的未来任务的概率期望值，如(3-2)所示：

$$\phi(r_p) = \sum_{\text{substack}s \in Ss > r_p} \pi_s \quad (3-2)$$

其中， $\phi(r_p)$ 随 r_p 单调递减， $r_p = 0$ （显存满）或 $r_p \geq \max(S)$ （剩余显存可容纳所有任务）时， $\phi(r_p) = 0$ （无碎片）； r_p 处于中间区间且无法匹配高概率需求任务时， $\phi(r_p)$ 趋近于 1（碎片严重）。

（3）集群总碎片率

目标函数优化目标为最小化集群所有 GPU 的总显存碎片率，同时引入迁移惩罚项避免无意义迁移，目标函数如下：

$$\min F = \sum_{p=1}^P \sum_{g=1}^8 \phi(r_{p,g}) + \epsilon \cdot \sum_{(j,g)} x_{j,g} \quad (3-3)$$

其中， P 为服务器数量， g 为 GPU 编号， $r_{p,g}$ 为服务器 p 的 GPU g 的剩余显存； $x_{j,g}$ 为 0-1 迁移决策变量（ $x_{j,g} = 1$ 表示将任务 j 迁移至 GPU g ）； ϵ 为迁移惩罚系数（小正数），用于打破成本相同时的决策僵局，避免不必要的迁移操作。

3.3.3 约束条件

约束 1：任务唯一性约束。每个推理任务在同一时刻仅能分配至 1 张 GPU 执行，无重复分配或遗漏，如(3-4)所示。

$$\sum_{p=1}^P \sum_{g=1}^8 x_{j,g} = 1, \quad \forall j \in \mathcal{J} \quad (3-4)$$

其中 $\mathcal{J}$ 为当前待迁移的推理任务集合。

约束 2：GPU 显存容量约束。单 GPU 上所有运行任务的显存占用总和不超过其最大显存容量，如(3-5)所示。

$$\sum_{j \in \mathcal{J}_g} v_j \leq V_{\max}, \quad \forall p \in \{1, \dots, P\}, \forall g \in \{1, \dots, 8\} \quad (3-5)$$

其中 $\mathcal{J}_g$ 为分配至 GPU g 的推理任务集合。

3.4 调度优化执行流程

如图 3 所示，系统首先初始化 GPU 集群、推理任务、机器人运动时序等基础数

据，通过历史数据校准显存碎片率函数；实时监测机器人状态，在其进入电梯静止期时触发迁移决策，利用 MILP 算法求解最优迁移方案以整合显存碎片；新推理任务到达时按剩余显存适配度最高策略分配至碎片率最低的 GPU；最后循环迭代上述核心流程，持续优化集群显存碎片状态。




图 5 资源调度流程图

研究基础

1. 多目标优化

(1) 一种用于工业生产的多目标寻优方法及系统（专利）



图 6 专利实质审查书

2. 云资源调度

(1) Jiaxi Shi, Jianchen Hu, Meng Zhang, Chengshuai Wu, GPU Cluster Scheduling via Dynamic Fragment-aware Live Migration (论文, IFAC2026)

研究 GPU 训练任务利用 checkpoint 时刻迁移, 以减小 GPU 碎片化程度, 提高系统整体利用率。

```
Manuscript data
=====
Submission number: 1016
Authors or proposers names and PINs:
Jiayi Shi (190357), Jianchen Hu (103769), Meng Zhang (77947),
Chengshuai Wu (92671)
Corresponding author or proposer:
Jianchen Hu, horace89@jtu.edu.cn, horacehu89@gmail.com
Title:
GPU Cluster Scheduling via Dynamic Fragment-aware Live
Migration
Date submitted: November 14, 2025
Type of submission: Invited session paper
Status: Received
Invited session identification code: 2322t
Award candidate: None
Keywords:
Data centers and cloud computing; Decision making under
uncertainty
Profile:
Invited Session
Abstract:
The proliferation of training requirements for generative
artificial intelligence (AI) has made the graphic
processing unit (GPU) scheduling a critical issue in cloud
computing. Due to the existence of uncertainty in the GPU
demand sequence, a poorly designed GPU scheduling algorithm
can result in severe GPU fragmentation, leading to low
resource utilization ratio and increased operational cost.
In order to solve this problem, we propose a new scheduling
algorithm that uses the intrinsic checkpointing mechanism
of AI training tasks to enable dynamic fragment-aware live
task migration, so that our approach can consolidate
dynamic fragmented GPU resources through rescheduling
tasks. Moreover, we introduce a dual-objective scheduling
strategy tailored to cluster workload which minimizes the
average fragmentation rate for dense workloads and
minimizes the task queuing time for sparse workloads. We
have verified the improvement of our algorithm in cluster
throughput and efficiency through a GPU scheduling
simulation example.
=====
```

图 7 论文投稿回执

(2) 华为云 HCC 多任务执行顺序编排优化（横向项目，2024.12-2025.12）

研究多约束条件下，升级任务的编排调度。




图 8 HCC 多任务执行编排

3. 单目深度估计

(1) 图像单目深度估计（科研项目，2025.6-2025.11）

研究无相机信息输入下，利用生成式模型进行密集预测，估计室内物品深度位置。




图 9 单目深度估计推理

(2) 目标检测与机械臂控制（科研项目，2025.1-2025.5）



图 10 双目摄像头目标检测

效果演示：以按按键1为例



图 11 机械臂控制

三、研究计划及预期进展

时间	研究内容	预期效果
2026.1-2026.2	1. 调研多机器人协同配送场景的任务特征、单目深度估计 SOTA 算法； 2. 梳理 GPU 调度、电梯约束等核心问题； 3. 确定双目标优化模型的目标函数（总时间 / 能耗）与约束条件	1. 形成《场景需求与技术现状调研报告》； 2. 明确模型核心变量与约束边界； 3. 完成模型框架初稿
	1. 设计多机器人 - 任务分配的	1. 完成 MILP 模型的

2026.3-2026.4	MILP 模型； 2. 开发单目深度估计推理的轻量化适配算法；	数学表达式与求解逻辑； 2. 实现深度估计算法的端侧推理加速；
2026.5-2026.6	1. 整合 “任务分配 + 路径规划 + 电梯调度” 的分层协同架构； 2. 调试优化模型的求解效率；	1. 形成完整的多目标优化模型代码； 2. 模型求解时间控制在 2s 以内（中小规模任务）；
2026.7-2026.8	1. 扩展仿真环境（支持 5-8 台机器人、跨 3 楼层场景）； 2. 开展仿真实验（测试不同任务密度下的模型性能）； 3. 优化调度策略的动态响应逻辑	1. 搭建高保真仿真环境（还原电梯运行、机器人载重等真实约束）； 2. 输出仿真性能报告； 3. 动态重求解响应时间 $\leq 5s$
2026.9-2026.10	1. 部署实物机械臂 + 移动小车硬件平台； 2. 联调算法与硬件（测试机械臂按电梯按钮、深度估计精度）； 3. 开展小规模实物验证实验	1. 实现硬件平台的稳定运行； 2. 单目深度估计相对误差 $\leq 15\%$ ； 3. 完成 10 次跨楼层配送的实物验证
2026.11-2027.5	梳理实验结果，撰写大论文	完成论文撰写
四、指导教师意见：		

签名：_____

日期：

五、选题汇报记录（着重记录对选题报告提出意见、评价、问题及对问题的解答等，如要修改时，指出修改的部分）

六、论文选题汇报评语（由参加开题报告的专家、教授填写）

开题报告小组签名：组长_____

成员_____

时间： 年 月 日